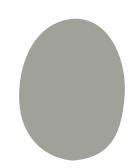




Tecnologías de datos masivos



Doble Grado en Ingeniería en Tecnologías de Telecomunicación y Business Analytics



Shuffle



Spark - Shuffle

- Spark mantiene el máximo tiempo posible la mayor cantidad posible de datos en memoria
- Hay determinadas operaciones que requieren datos que datos de distitnas paritciones se junte en una sola para poder operarar
- Estas operaciones llaman al proceso de **Shuffle**
- Cada vez que se llame a una operación que requiera shuffle se cambiará de stage
- Este proceso hace que lso datos de una partición dejen de estar en memoria y se escriban a disco

Spark - Shuffle

- Las transformaciones de shuffle son las más costosas a nivel computacional que se pueden hacer en Spark
- Se recomienda minimizar tanto el número de transformaciones de shuffle como los registros involucrados en la propia transformación
- Toda operación de shuffle en Spark requiere un RDD con clave valor aunque algunas,
 como distinct, generan el RDD de clave valor en la misma operación

- Ordena las distintas claves de un RDD del tipo clave valor
- A partir de esta orden los resultados están ordenados hasta que se modifique la clave
- Es una función del tipo wide por lo que llame a shuffle y termina un stage
- El RDD resultado tendrá el mismo número de registros que el RDD entrante
- sortByKey(): RDD[K, V]

```
(#LaPalma, 100)
```

```
>>>sorted_hashtags = hashtags.sortByKey()
```

```
(#LaPalma, 100)
```

```
>>>sorted_hashtags = hashtags.sortByKey()


sortByKey
```

```
>>>trendy_topic = hashtags.map(lambda hastag_hits:
  (hastag_hits[1],
  hastag_hits[0])).sortByKey(ascending=False).map(lambda
  hastag_hits: (hastag_hits[1], hastag_hits[0]))
```


```
(1,#EEUU)
(#Pandemic, 45)
```

```
>>>trendy_topic = hashtags.map(lambda hastag_hits:
  (hastag_hits[1],
hastag_hits[0])).sortByKey(ascending=False).map(lambda
hastag_hits: (hastag_hits[1], hastag_hits[0]))
```





```
>>>trendy_topic = hashtags.map(lambda hastag_hits:
  (hastag_hits[1],
  hastag_hits[0])).sortByKey(ascending=False).map(lambda
  hastag_hits: (hastag_hits[1], hastag_hits[0]))
```




- La función groupByKey agurpa todos los valores de una misma clave en un mismo registro
- Es del tipo Wide por lo que acaba un stage y llama a Shuffle
- En el RDD resultante todos los valores de una clave tienen que caber en una misma particion.
- Es la operación de combinación más ineficiente de Spark, sólo se usa cuando no hay otra opción
- El resultado tendrá tantos registros como claves tiene el RDD de entrada
- groupByKey() : RDD[K, List[V]]

```
>>>measure_grouped_by_cups = measure_by_cups.groupByKey()
.map(lambda key_values:(key_values[0],list(key_values[1])))
```

groupByKey

```
>>>measure_grouped_by_cups = measure_by_cups.groupByKey()
.map(lambda key_values:(key_values[0],list(key_values[1])))
                       groupByKey
```

```
>>>measure_grouped_by_cups = measure_by_cups.groupByKey()
.map(lambda key_values:(key_values[0],list(key_values[1])))
```



- La función reduceByKey agrega los valores de una misma clave.
- Es similar a la operación Reduce de Map&Reduce pero a diferencia del reduce, reduceByKey sólo puede utilizarse en operaciones que sean conmutativas y asociativas
- Es del tipo Wide por lo que acaba un stage y llama a Shuffle
- El resultado tendrá tantos registros como claves tiene el RDD de entrada
- reduceByKey([U, U] => U) : RDD[K,U]

```
>>>def get_max_hour_meassure(measure_hour1, measure_hour2):
    if measure_hour1[1] >= measure_hour2[1]:
        return measure_hour1
    else:
        return measure_hour2
>>>max_measure_and_hour_by_cups = measure_and_hour_by_cups
.reduceByKey(lambda: measure_hour1, measure_hour2:
get_max_hour_meassure(measure_hour1, measure_hour2))
```

```
(cups1, (15,17))
```

```
>>>def get_max_hour_meassure(measure_hour1, measure_hour2):
    if measure_hour1[1] >= measure_hour2[1]:
        return measure_hour1
    else:
        return measure_hour2
>>>max_measure_and_hour_by_cups = measure_and_hour_by_cups
.reduceByKey(lambda: measure_hour1, measure_hour2:
get_max_hour_meassure(measure_hour1, measure_hour2))
```






- Si el tipo de datos de la clave no es el que queremos para resolver nuestro problema podemos hacer un map o un flatMap previo
- Aumentan el tiempo de cálculo
- Reducen el número de elementos con los que hacer shuffle
- Siempre es preferible al groupByKey, pero hay casos en los que sólo se puede hacer un groupByKey(operaciones no conmutativas ni asociativas)


```
>>>amount_of_messurement_by_cups = measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
   (measure_and_hour_by_cups[0], measure_and_hour_by_cups[1][1]))
.reduceByKey(lambda: measure1, measure2: measure1 + measure2)
```

```
>>>amount_of_messurement_by_cups = measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
   (measure_and_hour_by_cups[0], measure_and_hour_by_cups[1][1]))
.reduceByKey(lambda: measure1, measure2: measure1 + measure2)
```



```
>>>amount_of_messurement_by_cups = measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
   (measure_and_hour_by_cups[0], measure_and_hour_by_cups[1][1]))
.reduceByKey(lambda: measure1, measure2: measure1 + measure2)
```






- Algunas operaciones no pueden resolverse directamente de manera conmutativa y asociativa
- Cambiando la forma en la que se procesan los datos podemos convertirlo en un problema que se puede resolver de manera conmutativa y asociativa.


```
>>>mean_messurement_by_cups = measure_by_cups
.reduceByKey(lambda: measure1, measure2: mean(measure1, measure2))
```

```
>>>mean_messurement_by_cups = measure_by_cups
.reduceByKey(lambda: measure1, measure2: mean(measure1, measure2))
```




```
>>>amount_of_messurement_by_cups =
measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
    (measure_and_hour_by_cups[0],
        (measure_and_hour_by_cups[1],1)))
.reduceByKey(lambda measure1, measure2:
    (measure1[0]+measure2[0], measure1[1]+measure2[1])
.map(lambda cups_sum_counter:
    (cups_sum_counter[0],
    cups_sum_counter[1][0]/cups_sum_counter[1][1]))
```

```
>>>amount_of_messurement_by_cups =
measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
    (measure_and_hour_by_cups[0],
        (measure_and_hour_by_cups[1],1)))
.reduceByKey(lambda measure1, measure2:
        (measure1[0]+measure2[0], measure1[1]+measure2[1])
.map(lambda cups_sum_counter:
        (cups_sum_counter[0],
        cups_sum_counter[1][0]/cups_sum_counter[1][1]))
```




```
>>>amount_of_messurement_by_cups =
measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
    (measure_and_hour_by_cups[0],
        (measure_and_hour_by_cups[1],1)))
.reduceByKey(lambda measure1, measure2:
        (measure1[0]+measure2[0], measure1[1]+measure2[1])
.map(lambda cups_sum_counter:
        (cups_sum_counter[0],
        cups_sum_counter[1][0]/cups_sum_counter[1][1]))
```





```
>>>amount_of_messurement_by_cups =
measure_and_hour_by_cups
.map(lambda measure_and_hour_by_cups:
    (measure_and_hour_by_cups[0],
        (measure_and_hour_by_cups[1],1)))
.reduceByKey(lambda measure1, measure2:
    (measure1[0]+measure2[0], measure1[1]+measure2[1])
.map(lambda cups_sum_counter:
    (cups_sum_counter[0],
    cups_sum_counter[1][0]/cups_sum_counter[1][1]))
```




Spark - join

- La función join junta los valores de dos RDDs con la misma clave.
- El resultado será una tupla en la cual la clave tendrá que ser la misma en ambos RDD y el valor una tupla con los valores de ambos RDD
- Es del tipo Wide por lo que acaba un stage y llama a Shuffle
- El resultado tendrá tantos registros como claves tiene en común ambos RDDs de entrada
- join(rdd[K, W]) : RDD[K,[V, W]]

Spark - join


```
>>>teachers_student_by_course =
   teachers_by_course.join(students_by_course)
```

Spark - join



Spark - tipos de joins

Spark nos deja hacer los distintos tipos de joins de sql



Spark - leftOuterJoin

```
>>>all_teachers_student_by_course =
   teachers_by_course.leftOuterJon(students_by_course)
```

```
(Algebra, prof1)
(Calculus, prof2)
(Sw Engineering , prof2)
```

```
(Algebra, alumn1)


(Logic, alumn1)

(Algebra, alum3)

(Algebra, alum2)

(Calculus, alum1)
```

Spark - leftOuterJoin



(Algebra, prof1) (Calculus, prof2)

Spark - rigthOuterJoin

```
>>>teachers_all_student_by_course =
   teachers_by_course.rigthOuterJoin(students_by_course)
```

Spark - rigthOuterJoin >>>teachers_all_student_by_course = teachers_by_course.rigthOuterJoin(students_by_course) (Calculus,

Spark - fullOuterJoin

```
>>>all_teachers_all_student_by_course =
   teachers_by_course.fullOuterJoin(students_by_course)
```

```
(Algebra, prof1)
(Calculus, prof2)
(Sw Engineering , prof2)
```

```
(Algebra, alumn1)
(Logic, alumn1)
(Algebra, alum3)
(Algebra, alum2)
(Calculus, alum1)
```

Spark - fullOuterJoin



Apache Spark